Università degli studi di Parma
Dipartimento di Ingegneria e Architettura

Sistemi operativi e in tempo reale – a.a. 2023/24

Dai *Processi* alla *Programmazione Concorrente*

Indice

- La natura sequenziale o non sequenziale dei problemi e delle nostre soluzioni
- La componente dinamica del processo: in questa lezione la chiameremo talvolta *processo* (denominazione tradizionale), anziché *thread* (terminologia attuale), in omaggio al tempo in cui queste idee sono state sviluppate
- Rappresentazione della esecuzione di un processo: eventi, traccia
- Classificazione delle situazioni e dei problemi

Processi

- In un sistema multiprogrammato la CPU esegue alternativamente, in un intervallo di tempo, *sequenze di operazioni appartenenti a processi diversi*; in un dato intervallo l'esecuzione di un processo può essere *sospesa e ripresa più volte*
- A differenza dei sistemi monoprogrammati, nei sistemi multiprogrammati occorre distinguere tra l'attività della CPU e l'esecuzione di un particolare processo

Processi

- In un sistema multiprogrammato *sono presenti contemporaneamente più processi/thread*
- Se il sistema hw dispone di una sola CPU, *un solo* processo in ogni istante può essere in *esecuzione*. Gli altri processi sono sospesi in attesa della CPU o del verificarsi di particolari condizioni che rendano possibile il proseguimento della loro esecuzione (es. completamento I/O)
- Stato di un processo/thread:
  - in esecuzione (running)
  - bloccato (waiting)
  - pronto (ready)

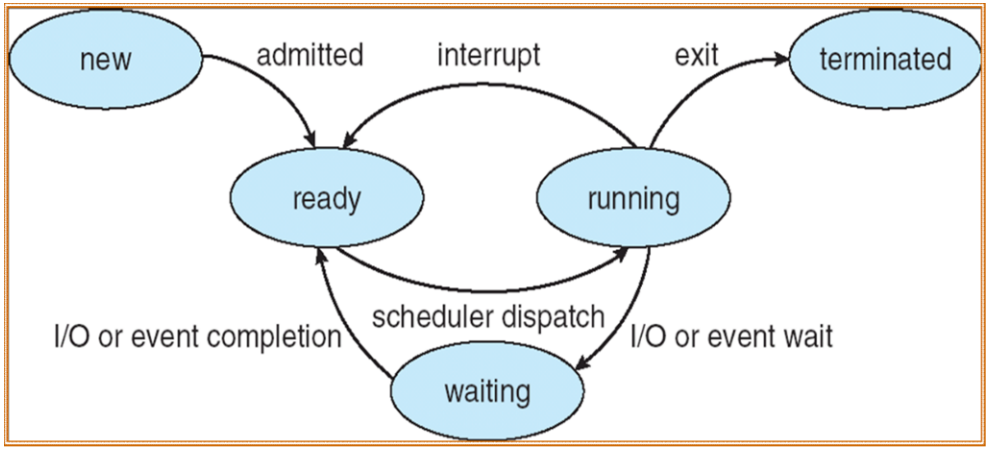

Processi

- Il concetto di processo rappresenta una *astrazione* della sequenza di operazioni svolte per eseguire un determinato programma, indipendentemente da:
  - processore fisico utilizzato
  - tempo di esecuzione
- E' uno strumento utile nello studio di sistemi in cui più attività evolvono *contemporaneamente*, in maniera reale o simulata (sistemi multiprogrammati, ma anche controllo dei processi industriali e altri tipi di sistemi)
- E' un'astrazione utile nella scomposizione di sistemi complessi

Cosa vediamo?

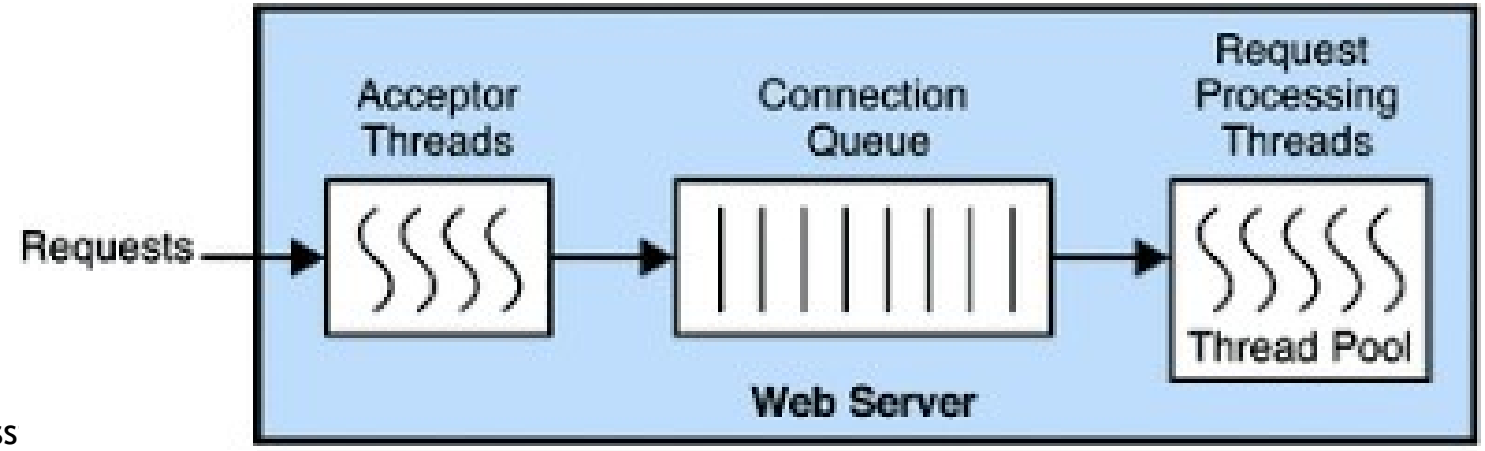

Livello di rappresentazione dei processi

Le *operazioni di un processo* possono essere descritte a *diversi livelli di dettaglio*:

- x := x + 1;

- ```
  LOAD    A,x
  INCR    A
  STORE   x,A
  ```

- ComputeNextItem(x);

- ```
  Im=GetImage();
  P_Im=ProcessImage(Im);
  Out=RenderImage(P_Im);
  ```

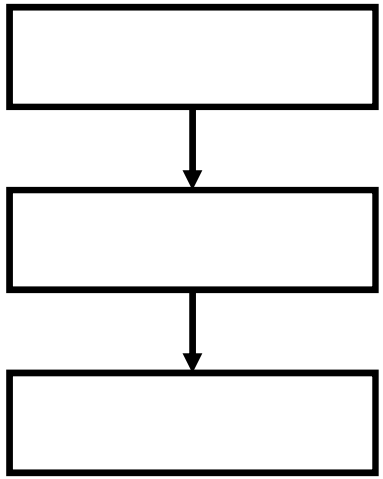

Gestione dei processi

- Poiché la CPU può essere commutata in un qualsiasi istante da un processo ad un altro è indispensabile *ad ogni commutazione salvare tutte le informazioni contenute nei registri della CPU* e relative al processo/thread che è stato sospeso (PC, accumulatori, registri indice, etc.)
- *Descrittore di processo o thread*, ovvero *process control block* (PCB) o *thread control block* (TCB): area di memoria, mantenuta entro l'area protetta del SO, associata al processo/thread e contenente tutte le informazioni proprie del processo/thread

Algoritmo, Programma, Processo

- *Algoritmo*: Procedimento logico che deve essere seguito per risolvere il problema in esame
- *Programma*: Descrizione dell'algoritmo tramite un opportuno formalismo (*linguaggio di programmazione*) che rende possibile l'esecuzione dell'algoritmo da parte di un particolare elaboratore
- *Processo (sequenziale)*: La sequenza di eventi cui dà luogo un elaboratore quando opera sotto il controllo di un particolare programma (evento = esecuzione di una operazione)

Rappresentazione di un processo

- Sequenza di *stati* attraverso i quali "passa" l'elaboratore durante l'esecuzione di un programma (storia del processo, traccia della esecuzione del programma)
- Esempio: Algoritmo di Euclide per il calcolo del M.C.D. di x e y (numeri naturali)

```
begin
    a := x; b :=y;
    while (a != b) do
                    if a > b then  a := a - b
                           else    b := b - a
end
```

Rappresentazione di un processo

x	18	18	18	18	18	18
y	24	24	24	24	24	24
a	-	18	18	18	12	6
b	-	-	24	6	6	6

- Lo stato è espresso dai valori delle variabili (oltre che dallo stato dei registri)
- Il processo può essere sospeso in qualsiasi stato

Un programma -> più processi

- Un programma descrive non un processo ma *un insieme* (potenzialmente infinito) *di processi*, ognuno dei quali è relativo all'esecuzione del programma da parte della CPU *per un determinato insieme di dati di ingresso*
- Processi che derivano dal medesimo programma possono essere attivi contemporaneamente

Grafo di precedenza

- Un processo può essere rappresentato tramite un *grafo orientato*, detto *grafo di precedenza* del processo
- I *nodi* del grafo rappresentano i *singoli eventi* del processo, mentre gli *archi* identificano le *precedenze temporali* tra tali eventi
- Il processo è *strettamente sequenziale* ➔ il grafo di precedenza è ad ordinamento totale (ogni nodo ha esattamente un predecessore ed un successore):

Grafo di precedenza

- Un processo può essere rappresentato tramite un *grafo orientato*, detto *grafo di precedenza* del processo
- I *nodi* del grafo rappresentano i *singoli eventi* del processo, mentre gli *archi* identificano le *precedenze temporali* tra tali eventi
- Il processo è *strettamente sequenziale*, ovvero il grafo di precedenza è ad ordinamento totale (ogni nodo ha esattamente un predecessore ed un successore) ➔

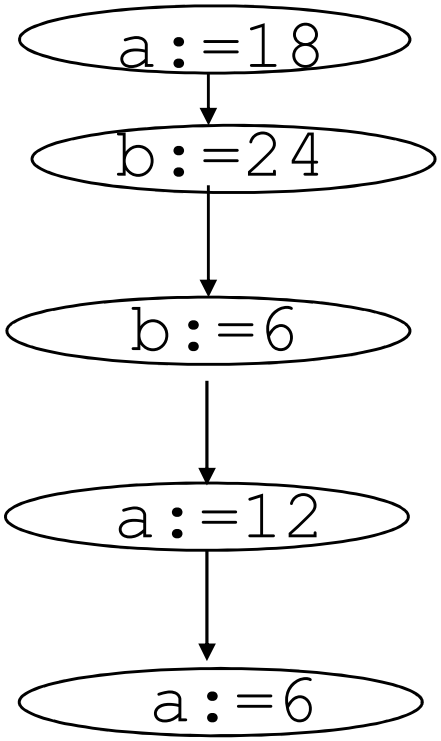

Processi non sequenziali

- L'ordinamento totale di un grafo di precedenza deriva in genere dalla *natura sequenziale* del processo (a sua volta imposta dalla natura sequenziale dell'elaboratore)
- In taluni casi l'ordinamento totale è *implicito* nel problema da risolvere, spesso è invece una *imposizione* che deriva dalla natura sequenziale dell'elaboratore
- Molte applicazioni potrebbero più naturalmente essere rappresentate da processi (*non sequenziali*) tra i cui eventi sussiste un ordinamento non totale ma *solo parziale*

Processi non sequenziali

- Esempio - Valutazione della espressione:

  (3 * 4) + (2 + 3) * (6 - 2)

- Grafo di precedenza ad ordinamento totale:

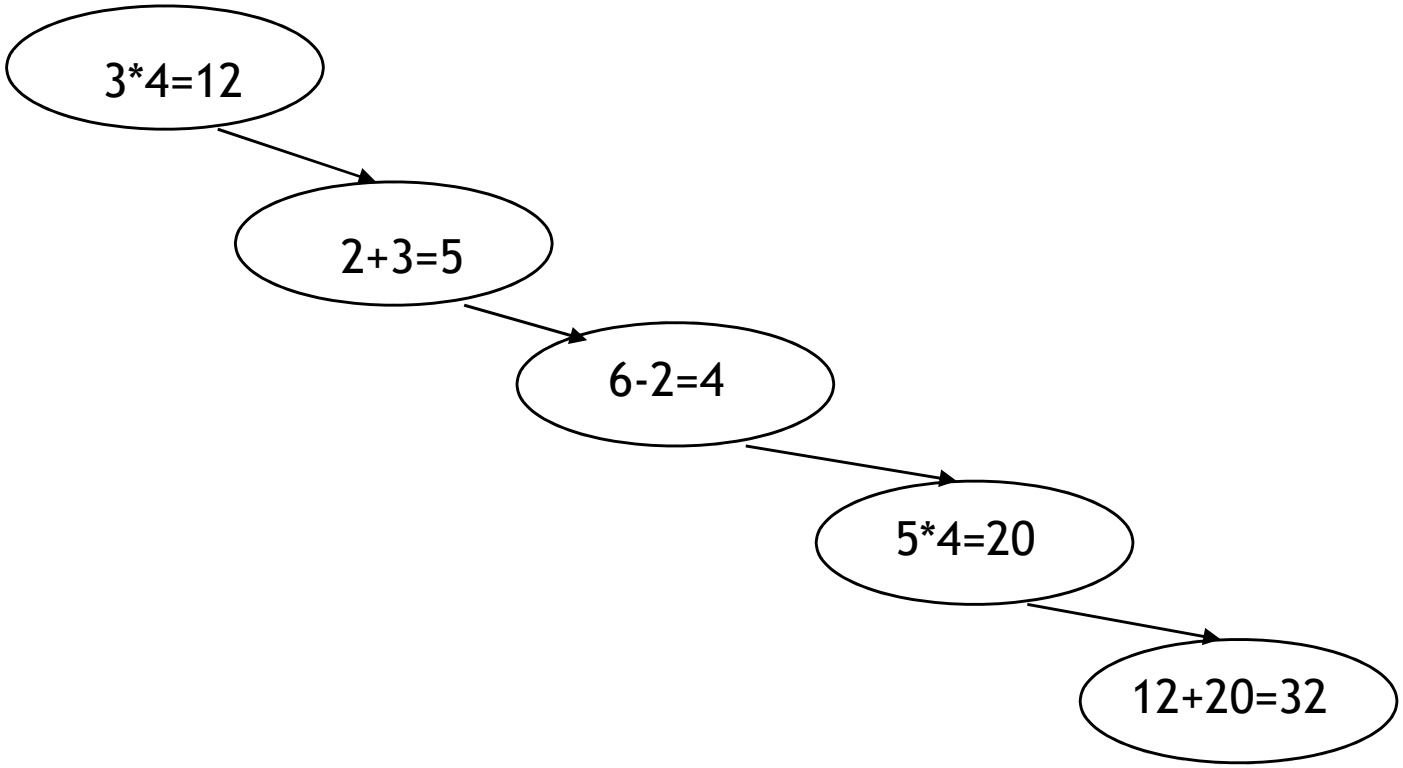

Processi non sequenziali

- Grafo di precedenza ad ordinamento parziale:

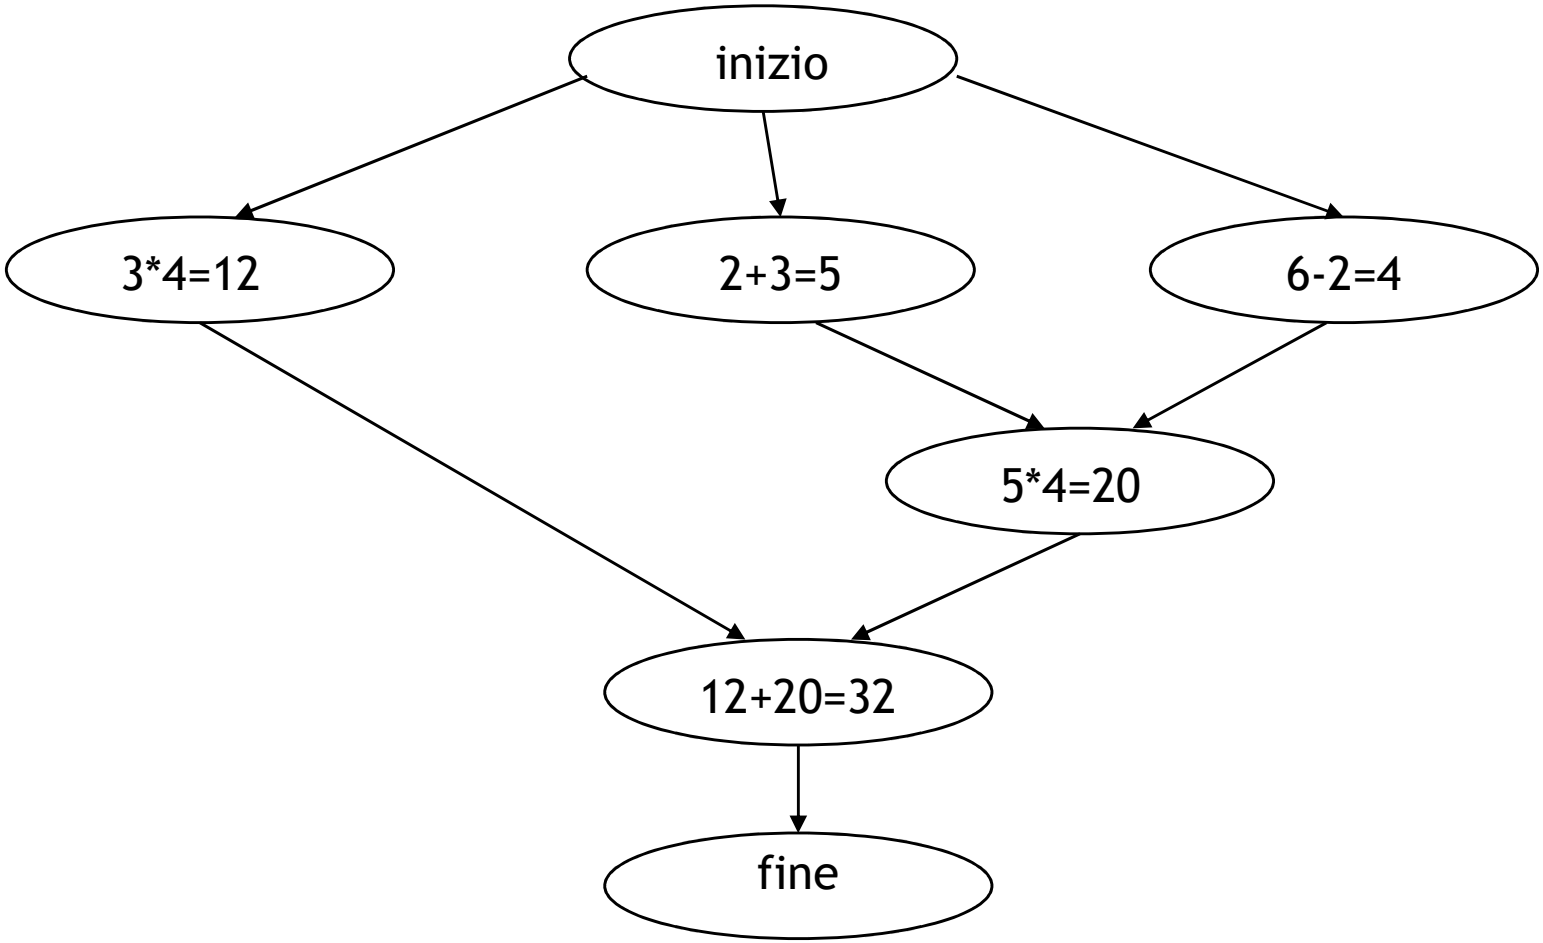

Processi non sequenziali

- Nell'esempio precedente la logica del problema *non impone* un ordinamento totale tra le operazioni da eseguire - ad esempio: tra (2+3) o (6-2)
- Le due operazioni tuttavia devono essere eseguite prima del prodotto dei loro risultati
- La presenza di eventi del processo tra cui non sussistono vincoli di precedenza ne denota la natura *non sequenziale*: il risultato dell'elaborazione è indipendente dall'ordine con cui si verificano tali eventi

Processi non sequenziali

- Esempio: Elaborazione dati su un file sequenziale

```
var      buffer: T;
   i: 1.. N;

begin
   for  i := 1 to  N do
        begin
           lettura (buffer);
           elaborazione (buffer);
           scrittura (buffer);
        end
end
```

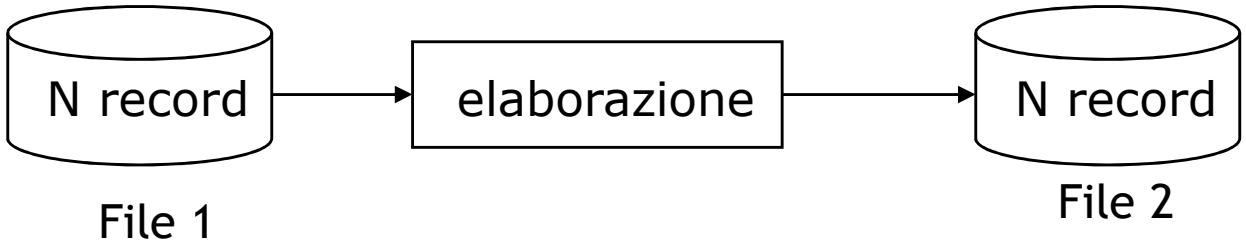

Processi non sequenziali

- Grafo di precedenza
  ad ordinamento totale

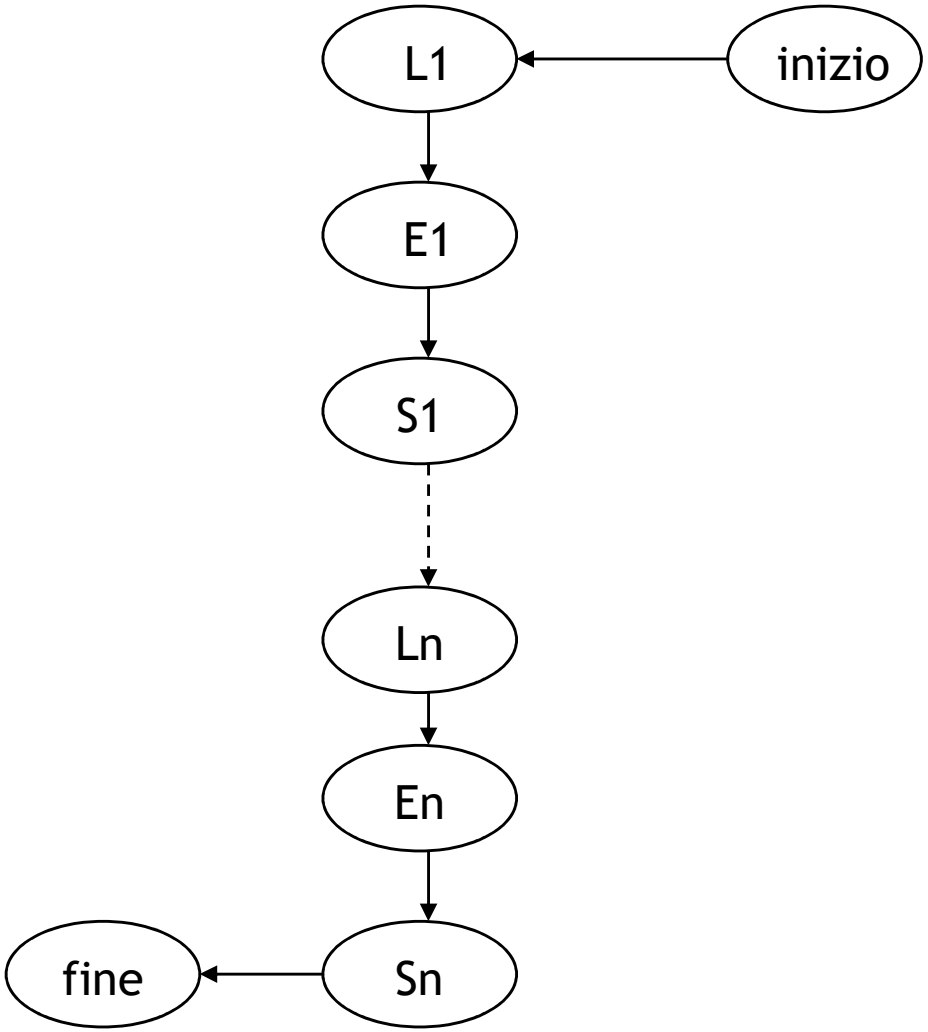

Processi non sequenziali

- Grafo di precedenza ad ordinamento parziale:

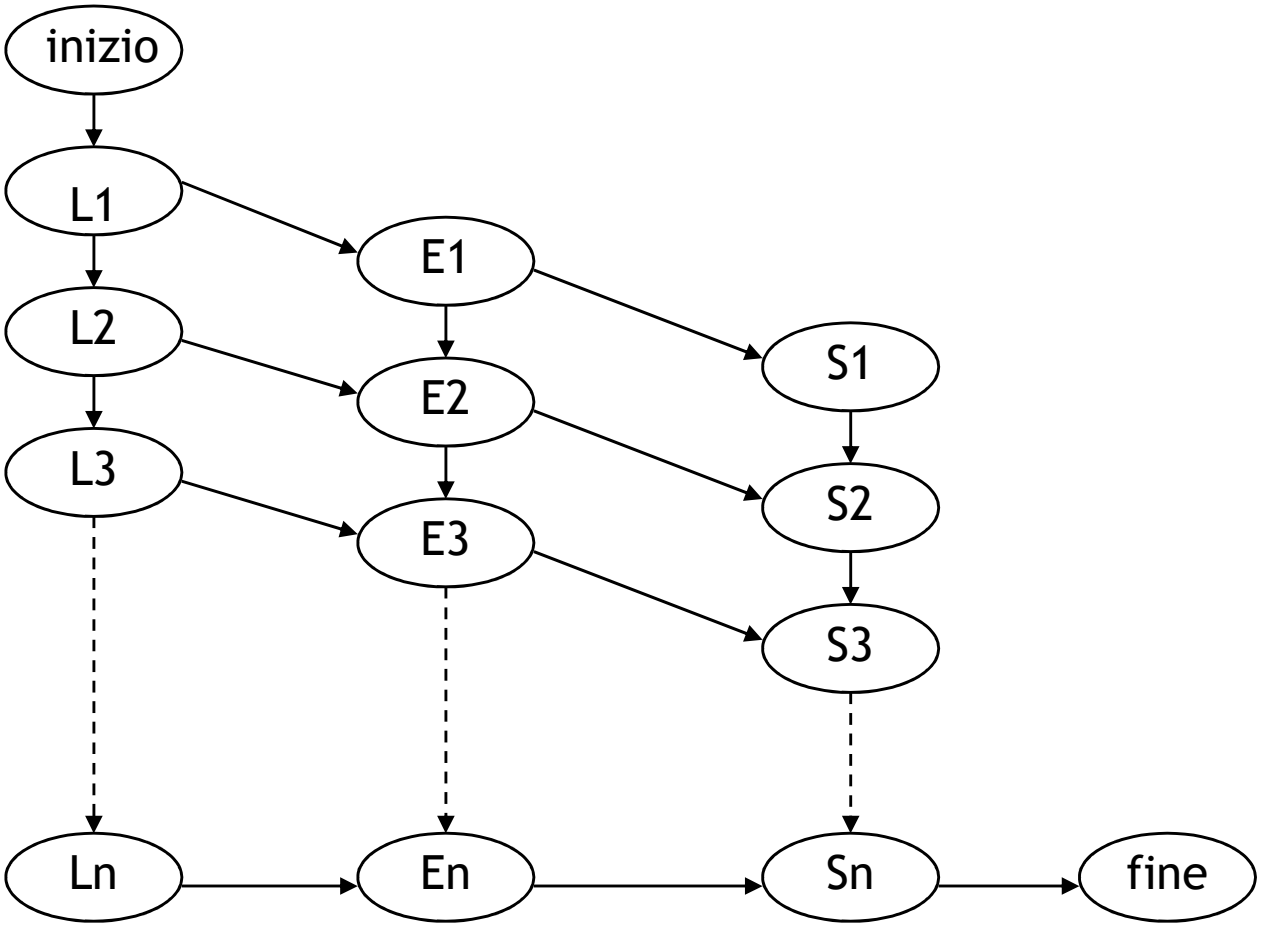

Processi non sequenziali

- Grafo di precedenza ad ordinamento parziale:

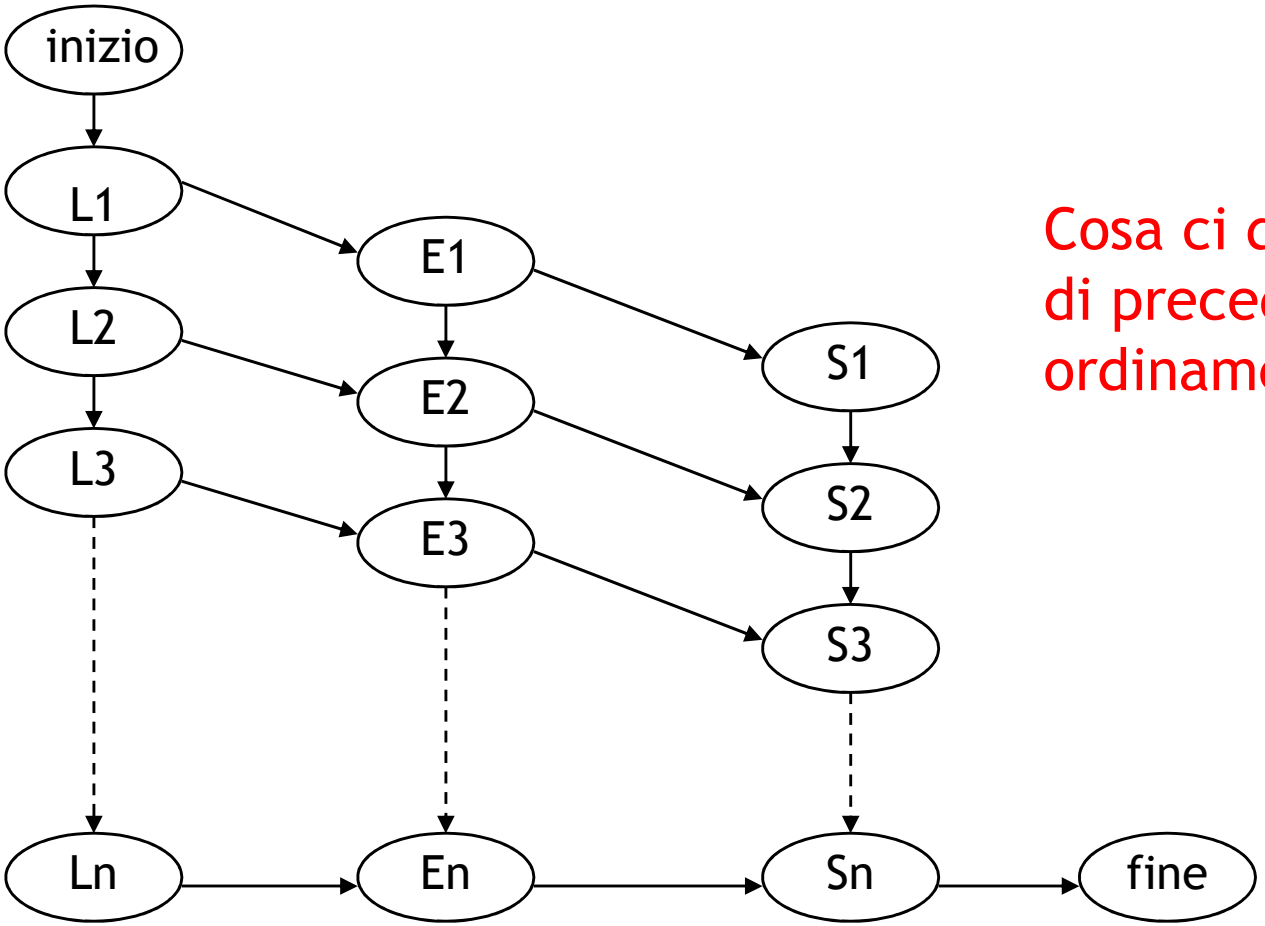

Cosa ci dice un grafo di precedenza ad ordinamento parziale?

Processi non sequenziali

- Un grafo di precedenza ad ordinamento parziale identifica un processo non sequenziale
- La rappresentazione dell'esecuzione di un programma tramite processo non sequenziale:
  - esprime il massimo grado di *parallelismo* interno del problema (efficienza)
  - costituisce la formulazione *più naturale* del problema
- Come trarre vantaggio da questa formulazione?
- L'esecuzione di un processo non sequenziale richiede:

  1) elaboratore non sequenziale

  2) linguaggio di programmazione non sequenziale

Processi non sequenziali

- Elaboratore non sequenziale (in grado di eseguire più operazioni contemporaneamente):
  - architetture parallele e multicore (a)
  - sistemi multielaboratori (a)
  - sistemi monoelaboratore (b)

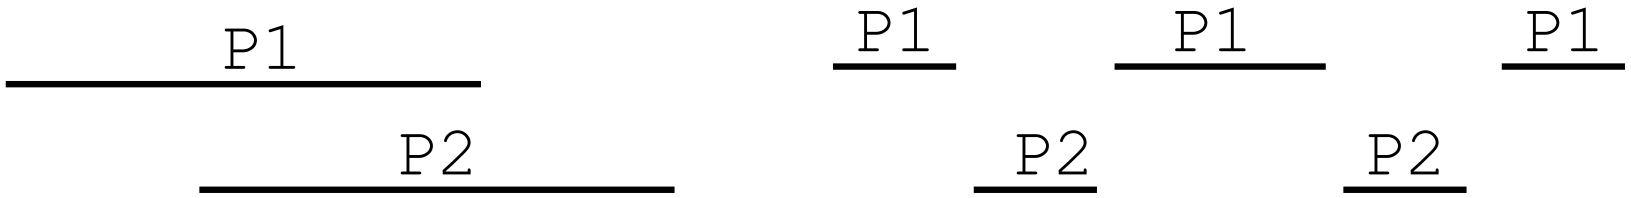

(a) (b)

parallelismo e concorrenza *concorrenza*

Linguaggio non sequenziale

- E` difficile per il programmatore riuscire a dominare la complessità di un algoritmo non sequenziale
- I linguaggi di programmazione non sequenziale consentono di descrivere una elaborazione non sequenziale come *composizione di processi sequenziali* eseguiti "contemporaneamente", ma analizzati e programmati *separatamente*
  → *processi concorrenti* (in terminologia attuale spesso saranno ***thread concorrenti***)
- → Semplificazione, modularizzazione dello sviluppo e della comprensione del programma complessivo
- L'attività svolta dall'elaboratore dedicato di *ciascun processo sequenziale* può essere rappresentata da un grafo di precedenza ad ordinamento totale

Programmazione non sequenziale: Classificazione

- Scomposizione della elaborazione di un algoritmo parallelo in *processi sequenziali concorrenti*
- Classificazione:
  - *processi indipendenti*: il grafo di precedenza è costituito da un insieme di sottografi ad ordinamento totale tra loro non connessi. Ogni sottografo identifica un processo
  - *processi interagenti*: il grafo di precedenza è un grafo connesso ad ordinamento parziale. Si individua sul grafo un insieme (P1... Pn) di *sequenze di nodi*, su ognuna delle quali cioè vale un ordinamento totale

Processi indipendenti

- Processi *asincroni*: la velocità relativa delle diverse CPU virtuali può essere totalmente diversa

- L'evoluzione di un processo *non influenza* quella dell'altro

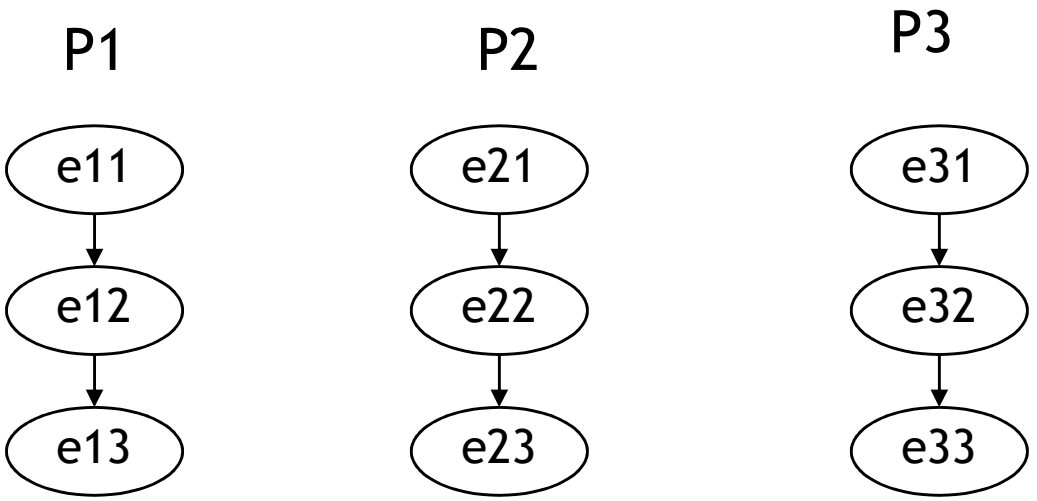

Processi interagenti

- Esempio dell'elaborazione su nastro: processo di lettura (P1), processo di elaborazione (P2), processo di scrittura (P3)

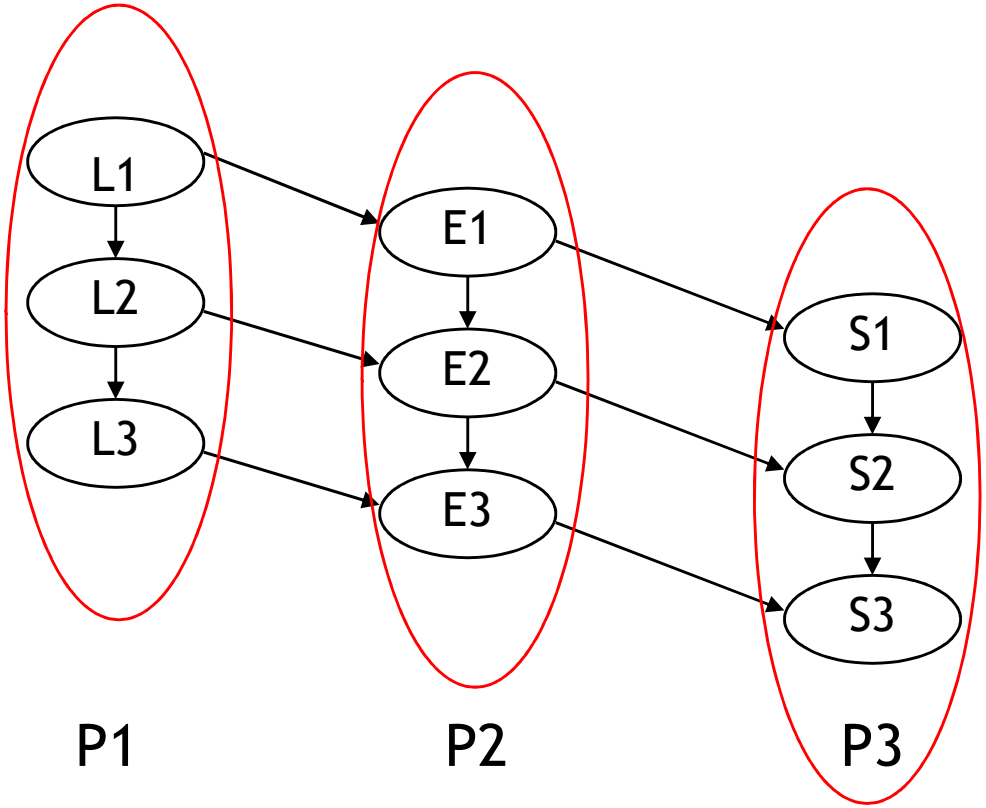

Processi interagenti

- Un *arco che collega nodi di processi diversi* rappresenta un *vincolo di precedenza* tra i corrispondenti eventi
- Affinché i processi interagenti esprimano correttamente la elaborazione non sequenziale è necessario imporre vincoli di precedenza tra le operazioni dei processi (*vincoli di sincronizzazione*): corrispondono agli archi omessi del grafo parzialmente ordinato di partenza
- Vincolo di sincronizzazione: *ordinamento di eventi*
- I processi possono essere eseguiti indipendentemente ma debbono rispettare tali vincoli
- La scomposizione in generale *non è unica*: conviene individuare un insieme di processi che dia luogo a poche interazioni

Processi concorrenti

- Due processi o thread si dicono concorrenti se la loro esecuzione *si sovrappone* nel tempo

overlapping

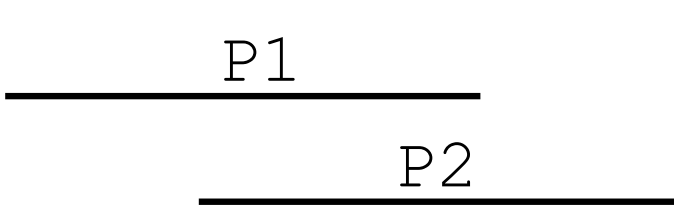

interleaving

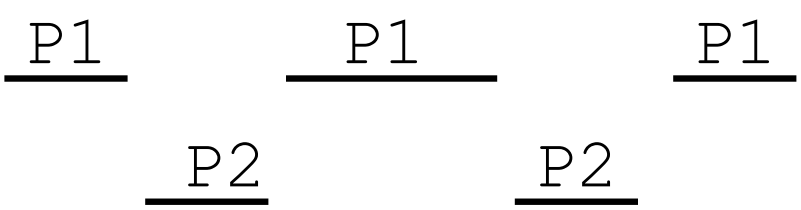

- Più in generale: due processi o thread sono concorrenti se *la prima operazione di un processo / thread inizia prima dell'ultima operazione dell'altro*

Processi concorrenti

- Motivi per una esecuzione in parallelo:
  - *condivisione* di risorse fisiche
  - *condivisione* di risorse logiche
  - incremento della *velocità* di esecuzione
  - *modularità*

- La velocità di esecuzione migliora grazie alla suddivisione del task in sottotask, ciascuno dei quali eseguito in parallelo con altri:
  - presuppone la presenza di elementi multipli di elaborazione centrali e/o dedicati
  - multicore

Relazioni tra processi

- Processi indipendenti:

  un processo è indipendente se *non può* influenzare o essere influenzato da altri processi
- Caratteristiche:
  - il suo stato *non è condiviso* da altri processi
  - la sua esecuzione è *deterministica*: il risultato della esecuzione dipende solo dallo stato di ingresso
  - la sua esecuzione è *riproducibile*: il risultato dell'esecuzione è sempre lo stesso per un medesimo stato di ingresso
  - la sua esecuzione può essere *bloccata e fatta ripartire* senza provocare danni

Relazioni tra processi

- Processi interagenti:

  un processo è interagente (ad es. cooperante) se può influenzare o essere influenzato da altri processi
- Caratteristiche:
  - il suo stato *è condiviso* da altri processi
  - la sua esecuzione è *non deterministica*: il risultato della sua esecuzione dipende dalla sequenza di esecuzione relativa dei processi e non è predicibile
  - la sua esecuzione è *non riproducibile*: il risultato non è sempre lo stesso per il medesimo stato di ingresso

Interazione tra processi

- Cooperazione:
- Comprende tutte le interazioni *prevedibili e desiderate*, insite cioè *nella logica dei programmi* (archi nel grafo di precedenza ad ordinamento parziale)
- Prevede *scambio di informazioni*:

  - segnale temporale (senza trasferimento di dati)

  - messaggi (dati)
- In entrambi i casi esiste un *vincolo di precedenza* (*sincronizzazione*) tra gli eventi di processi diversi; nel secondo caso è presente anche una *comunicazione* di dati tra i processi

Processi cooperanti

- Esempio: processo orologio (Real-Time Clock)
- *Cooperazione* con scambio di segnali temporali
  - Problematica tipica dei sistemi real-time per il controllo di processo

Esempio di cooperazione: Processo orologio (real-time clock)

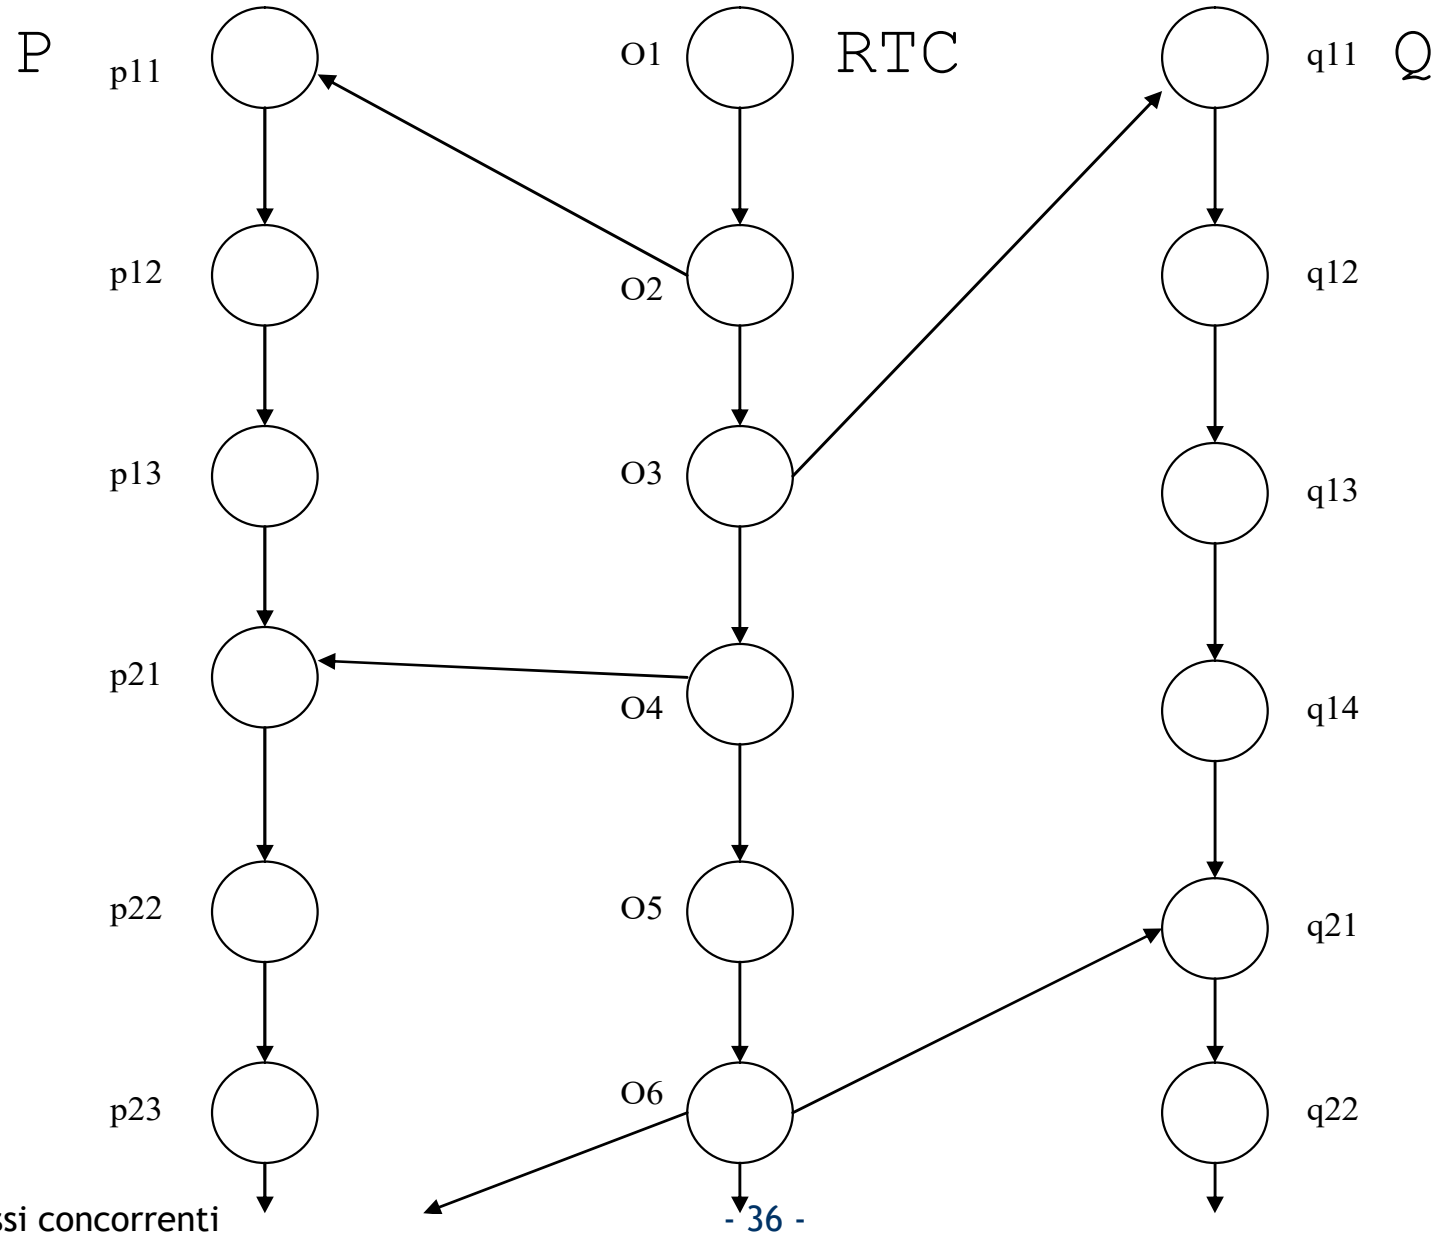

Interazione tra processi

- Competizione:
- La "macchina concorrente" su cui i processi /thread sono eseguiti mette a disposizione un *numero limitato di risorse*
- → Competizione per l'uso di risorse comuni che *non possono essere usate contemporaneamente*
- Interazione *prevedibile e non desiderata ma necessaria*

Processi in competizione

- Esempio: accesso ad un dispositivo di output condiviso
  - Es. *Telescrivente* / Teletype / TTY
  - (archeologia informatica!)
- *Competizione* per accedere al dispositivo in maniera mutuamente esclusiva
- Due processi P e Q includono *sequenze di eventi* (ps_1, ps_2, ...ps_n) e (qs_1, qs_2, ... qs_m) che non possono essere eseguite in maniera concorrente tra loro, ma non è necessario un particolare ordinamento tra le sequenze

Esempio di competizione: Accesso a dispositivo di output condiviso

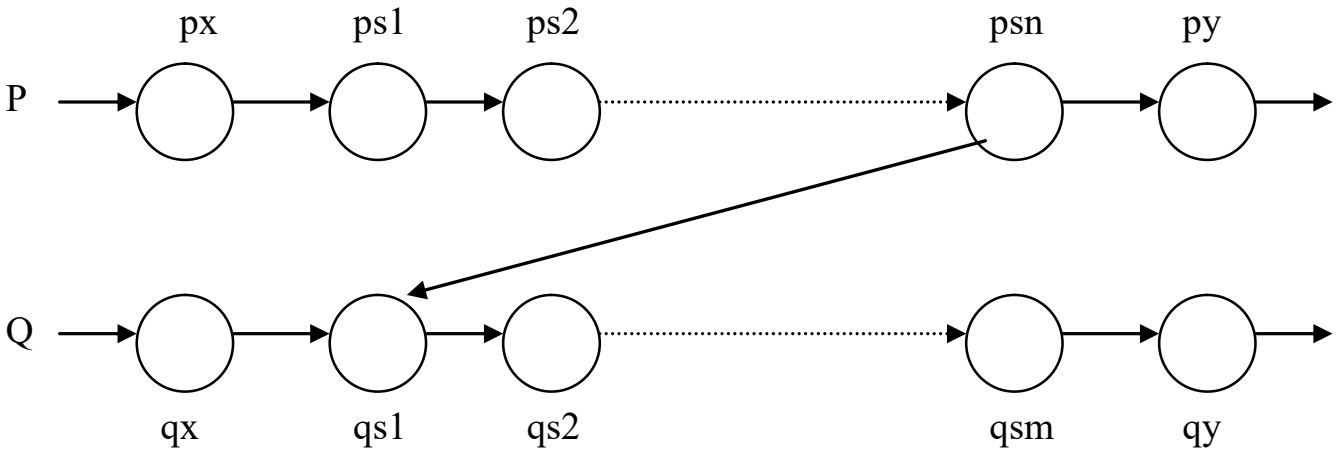

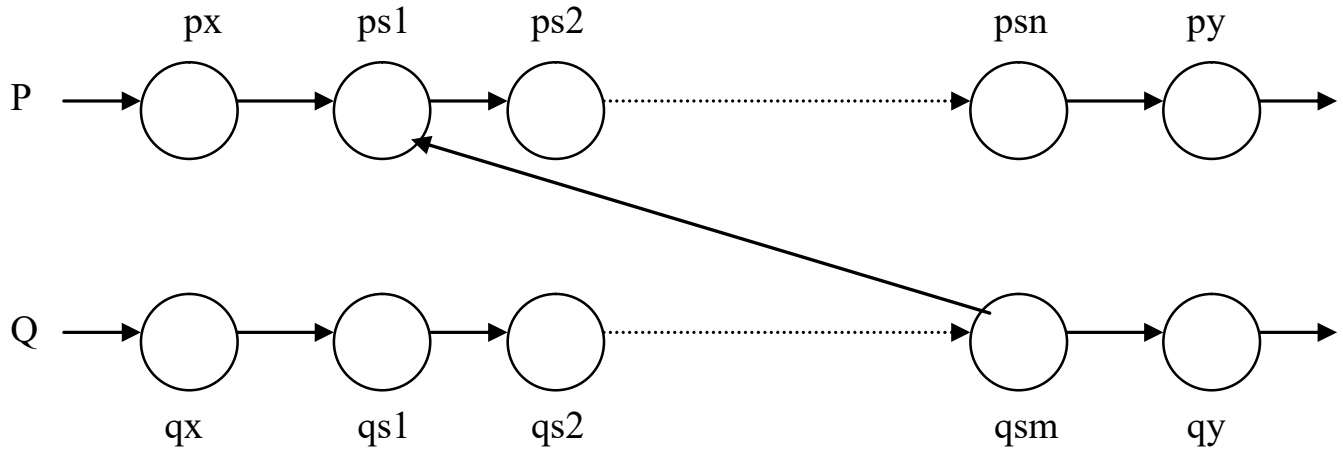

Interazione tra processi

- Cooperazione => Sincronizzazione diretta o esplicita
- Competizione => Sincronizzazione indiretta o implicita

- Esistono altre forme di interazione?

Interazione tra processi

- Interferenza
- Provocata da *errori di programmazione*:
  - inserimento nel programma di interazioni tra processi non richieste dalla natura del problema
  - erronea soluzione a problemi di interazione (cooperazione e competizione) necessari per il corretto funzionamento del programma
- Interazione *non prevista e non desiderata*
- Dipende dalla *velocità relativa* tra i processi: "gli effetti possono o meno manifestarsi nel corso dell'esecuzione del programma a seconda delle diverse condizioni di velocità di esecuzione dei processi" (*errori dipendenti dal tempo*)

Il quarto caso

- Interazione non prevista ma desiderata

- Programmazione evolutiva?
- Caos primordiale?
- Biglietto della lotteria?

- La legge (empirica) di Murphy suggerisce che interazioni di questo tipo siano poco plausibili: interazioni impreviste tra thread/processi si traducono quindi in *interferenze*!

Processi interferenti

- Problema fondamentale della programmazione concorrente: *eliminazione delle interferenze*
- L'eliminazione delle interferenze del primo tipo è semplificata se la macchina concorrente fornisce *meccanismi di protezione degli accessi*
  → *spazio di indirizzamento, concetto di processo*
- Le interferenze del secondo tipo sono *previste* ma programmate in modo errato → la protezione degli accessi non risolve!
- Servono tecniche di *programmazione concorrente strutturata*
  → *Programmazione multithread*

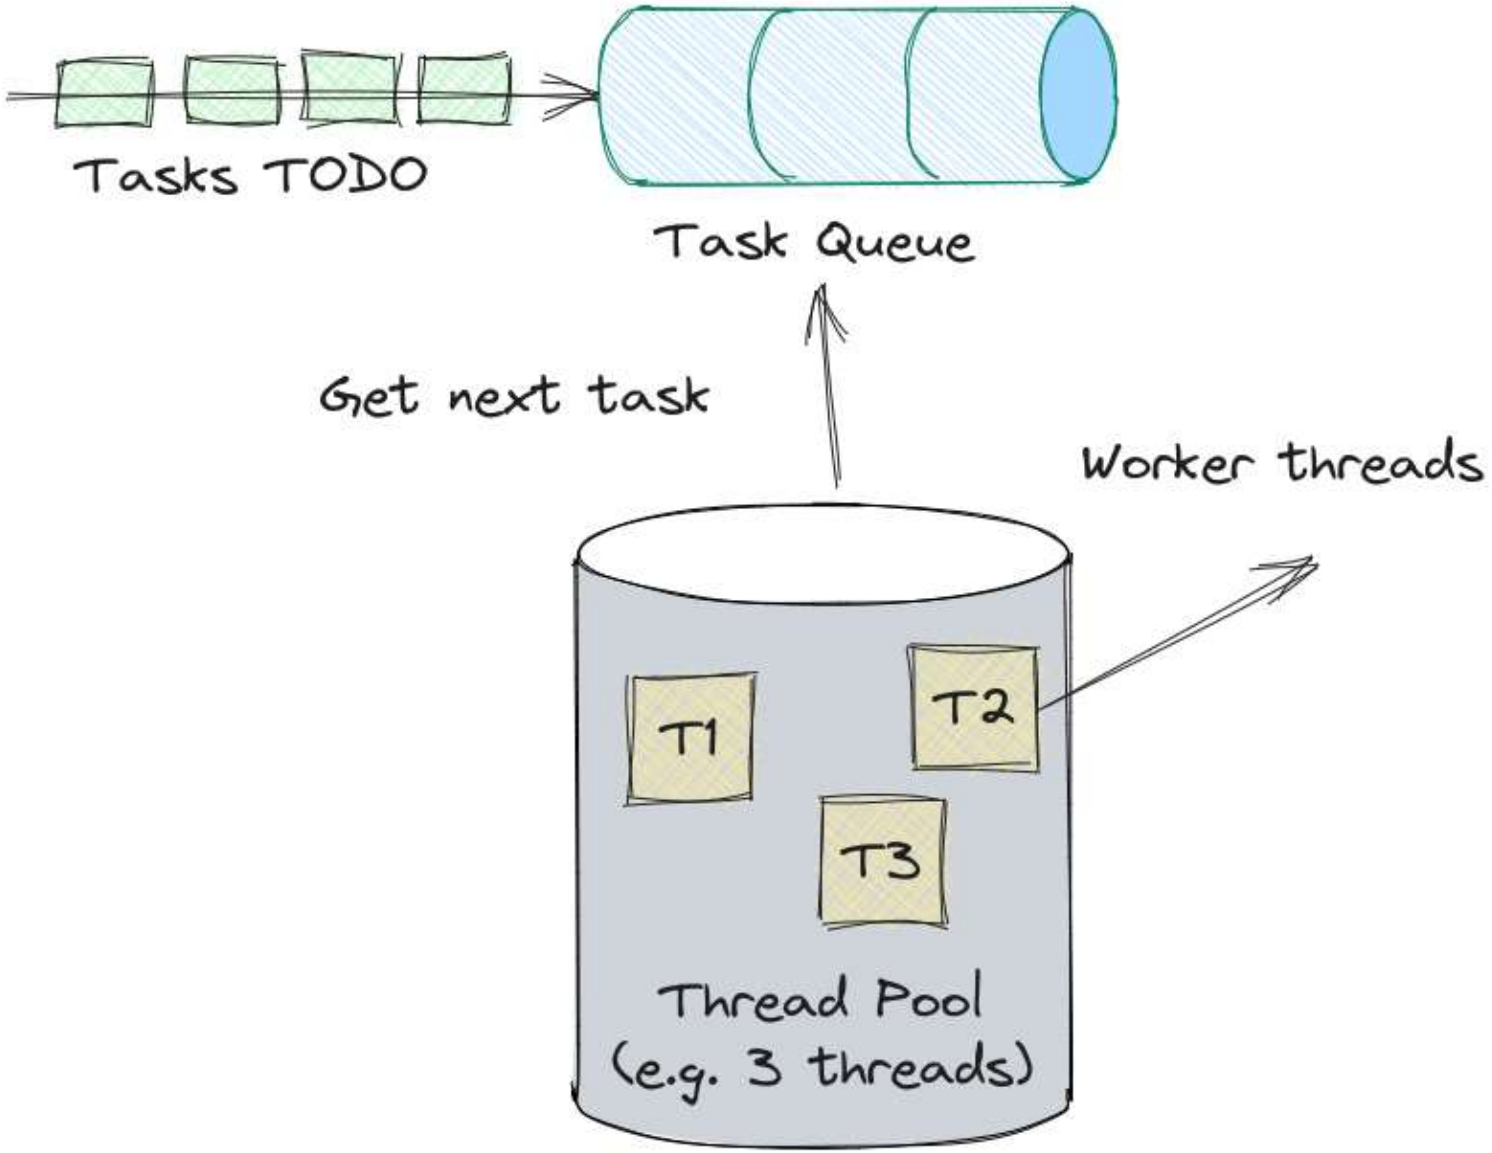
Tasks TODO
Task Queue
Get next task
Worker threads
T1
T2
T3
Thread Pool
(e.g. 3 threads)

Thread

- Un thread è una singola sequenza di esecuzione che rappresenta un task schedulabile individualmente
- I thread sono un meccanismo per la concorrenza, che consente cioè una esecuzione non serializzata dei task
  - sono le unità di esecuzione concorrente fornite dal SO
- Abilitano anche una esecuzione parallela (simultanea) in presenza di un supporto fisico multicore
- Un dominio di protezione può contenere uno o più thread (concetto ortogonale)
- Esecuzione concorrente di più thread:
  - può avvenire con qualsiasi ordine e interleaving
  - thread eseguiti fino al completamento oppure revocati e ripresi una o più volte, in qualsiasi modo e ordine

Motivazione per i thread: contemporaneamente

- I SO devono gestire più attività (processi, interrupt, attività di servizio in background)
- I server di rete devono gestire più connessioni
- I programmi paralleli eseguono più elaborazioni, per ottenere migliori prestazioni
- Programmi con interazione con utente devono garantire prontezza nella risposta mentre eseguono elaborazioni
- Programmi I/O bound (rete e disco) devono mascherare latenza eseguendo più elaborazioni

- ➔ «contemporanemente» ➔ thread (al plurale)

L’astrazione thread

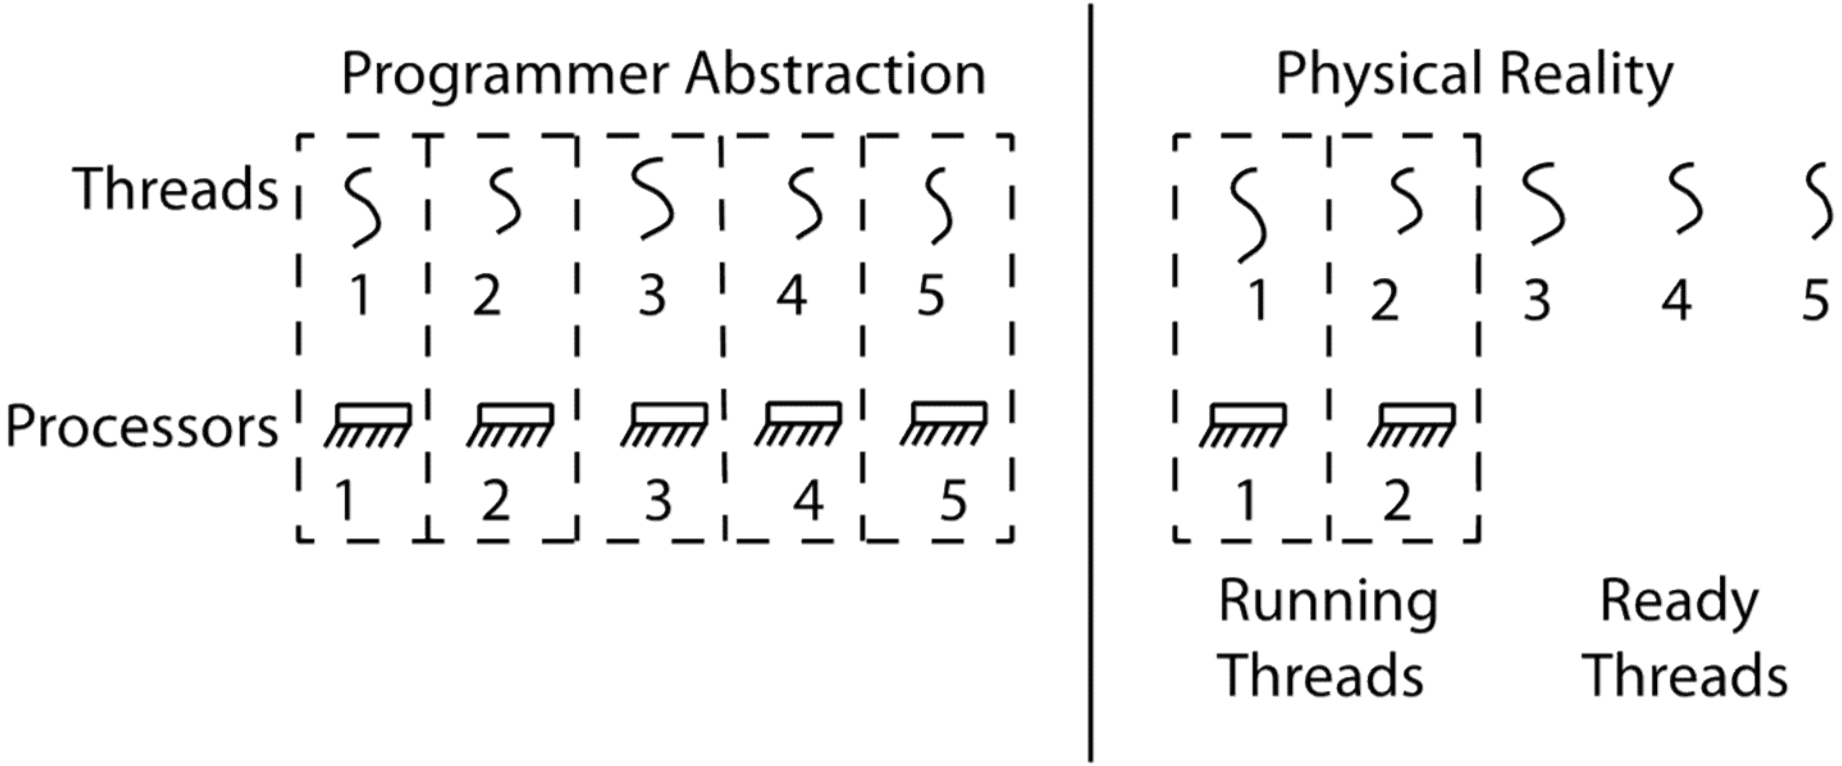

- Virtualizzazione: numero infinito di processori
- Realtà: i thread eseguono con «velocità» variabile
- $\Rightarrow$ I programmi devono essere progettati per eseguire correttamente con qualsiasi velocità dei thread

Vista del programmatore e realtà

Programmer's View	Possible Execution #1	Possible Execution #2	Possible Execution #3
.	.	.	.
.	.	.	.
.	.	.	.
x = x + 1;	x = x + 1;	x = x + 1	x = x + 1
y = y + x;	y = y + x;	.....	y = y + x
z = x +5y;	z = x + 5y;	thread is suspended	.....
.	.	other thread(s) run	thread is suspended
.	.	thread is resumed	other thread(s) run
.	.	.....	thread is resumed
		y = y + x	.....
		z = x + 5y	z = x + 5y

Modalità di esecuzione concorrente

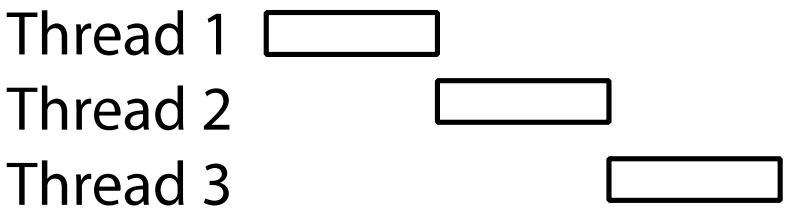

a) One execution

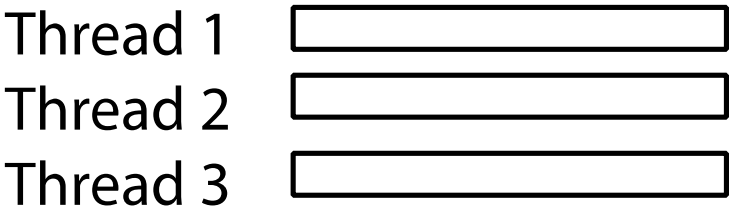

b) Another execution

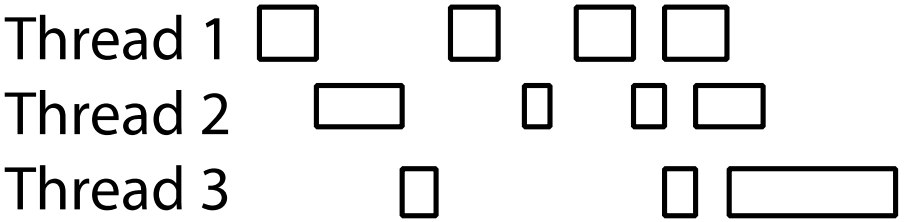

c) Another execution

Correttezza in presenza di thread concorrenti

- *Non determinismo*
  - Lo scheduler può eseguire i thread in qualsiasi ordine
  - Lo scheduler può commutare i thread in qualsiasi istante
  - Il testing dell'applicazione può essere molto complicato
- *Thread indipendenti*
  - non c'è stato condiviso con altri thread
  - condizioni deterministiche e riproducibili
- *Thread cooperanti*
  - stato condiviso tra più thread

- Obiettivo: ***Correctness by design***

Pattern di programmazione concorrente

- Il SO, tramite scheduler e dispatcher, può scegliere e mettere in esecuzione i thread / processi in un ordine arbitrario…
- I programmi devono funzionare correttamente in tutti i casi e *con tutti gli ordinamenti possibili*!

- I collaudi («test») non sono in grado di garantirlo!
  - "life-testing of ultrareliable software is infeasible (i.e., to quantify 10^{-8}/h failure rate requires more than 10^{8} h of testing)", in: Butler and Finelli, *The Infeasibility of Quantifying the Reliability of Life-Critical Real-Time Software, IEEE Trans. on Software Eng., 1993*
- ==> è necessario adottare *pattern* di programmazione concorrente